Pertemuan 9
Regresi Linier, Least Squares, dan Pandas

Pemrograman untuk Ilmu Data dan Komputasi

MA25-21008 Kelas RA dan RB

Triyana Muliawati, S.Si., M.Si.
Rifky Fauzi

Program Studi Matematika
Institut Teknologi Sumatera

Semester Ganjil 2026/2027

Pokok bahasan

- Peran matematika pada era data berskala besar.
- Regresi linier sederhana dan prinsip least squares.
- Pengelolaan dan visualisasi data dengan Pandas.
- Estimasi parameter dan evaluasi model.
- Regresi linier berganda dalam bentuk matriks.
- Pengantar model machine learning dan optimisasi.

Era Big Data dan Peran Matematika

Era data berskala besar

Data kini berasal dari transaksi, sensor, citra, eksperimen, survei, dan sistem digital. Banyak data membuka peluang baru, tetapi **data sendiri belum menjadi pengetahuan**.

Pertanyaan yang ingin dijawab

- Apakah variabel-variabel saling berhubungan?
- Dapatkah pola digunakan untuk memperkirakan nilai baru?
- Bagaimana memilih keputusan yang didukung data?

Peran matematika

Matematika memberi kerangka untuk

- merepresentasikan hubungan antarvariabel,
- mengukur kesalahan dan ketidakpastian,
- mencari parameter atau keputusan terbaik,
- menilai apakah suatu model cukup berguna.

Dari data menuju model

Data observasi $\rightarrow$ model matematis $\rightarrow$ estimasi parameter $\rightarrow$ evaluasi $\rightarrow$ interpretasi/prediksi.

Pemodelan Hubungan Antarvariabel

Contoh sederhana

Misalkan x menyatakan jam belajar dan y menyatakan nilai. Pertanyaannya:

bagaimana nilai berubah ketika jam belajar berubah?

Model paling sederhana

Salah satu pendekatan adalah menganggap hubungan tersebut mendekati garis lurus:

$$\hat{y}_i = \beta_0 + \beta_1 x_i.$$

β_0 adalah intercept dan β_1 adalah perubahan rata-rata y untuk kenaikan satu unit x.

Masalah matematis

Data nyata umumnya tidak tepat berada pada satu garis. Jadi masalahnya adalah memilih

garis yang paling dekat dengan data.

Menentukan β_0 dan β_1 dari data merupakan **estimasi parameter**. Untuk model garis lurus, hasilnya adalah regresi linier sederhana.

Least Squares pada Regresi Linier Sederhana

Untuk setiap observasi, selisih antara data dan model disebut residual:

$$e_i = y_i - \hat{y}_i = y_i - (\beta_0 + \beta_1 x_i).$$

Fungsi objektif

Least squares memilih parameter yang meminimumkan jumlah kuadrat residual:

$$S(\beta_0, \beta_1) = \sum_{i=1}^{n} [y_i - (\beta_0 + \beta_1 x_i)]^2 .$$

Hasil minimisasi

Dari $\partial S/\partial \beta_0 = 0$ dan $\partial S/\partial \beta_1 = 0$ diperoleh

$$\beta_1 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2}, \qquad \beta_0 = \bar{y} - \beta_1 \bar{x}.$$

Makna

Kita tidak memilih parameter secara coba-coba. Parameter diperoleh dari suatu **masalah minimisasi** yang dapat diturunkan secara matematis.

Algoritma Regresi Linier Sederhana

Langkah perhitungan

1. Input pasangan data (x_i, y_i), $i = 1, \ldots, n$.
2. Hitung $\bar{x}$ dan $\bar{y}$.
3. Hitung $s_{xy} = \sum(x_i - \bar{x})(y_i - \bar{y})$ dan $s_{xx} = \sum(x_i - \bar{x})^2$.
4. Hitung $\beta_1 = s_{xy}/s_{xx}$.
5. Hitung $\beta_0 = \bar{y} - \beta_1\bar{x}$.
6. Prediksi $\hat{y}_i = \beta_0 + \beta_1 x_i$.
7. Hitung residual $e_i = y_i - \hat{y}_i$.

```python
import numpy as np

def regresi_sederhana(x, y):
    xbar = np.mean(x)
    ybar = np.mean(y)
    sxy = np.sum((x-xbar)*(y-ybar))
    sxx = np.sum((x-xbar)**2)

    b1 = sxy / sxx
    b0 = ybar - b1*xbar
    yhat = b0 + b1*x
    resid = y - yhat
    return b0, b1, yhat, resid
```

Membaca dan memeriksa data

```
import pandas as pd

df = pd.read_csv("data.csv")
print(df.head())
print(df.shape)
print(df.isna().sum())

x = df["jam_belajar"].to_numpy()
y = df["nilai"].to_numpy()
```

Visualisasi awal

```
ax = df.plot.scatter(
    x="jam_belajar",
    y="nilai"
)
```

Scatter plot membantu melihat apakah asumsi hubungan linier masuk akal sebelum model dihitung.

Peran Pandas pada tahap ini

Pandas menangani data dan visualisasi. **Parameter model tetap dihitung dari rumus matematika yang telah diturunkan.**

Estimasi Parameter dan Evaluasi Model

"Essentially, all models are wrong, but some are useful." — *George E. P. Box (1976)*

Mengapa data dipisahkan?

Model perlu dinilai pada data yang tidak dipakai untuk mengestimasi parameternya. Karena itu:

- **data latih**: mengestimasi parameter model;
- **data uji**: mengukur kinerja model pada data baru.

$$\text{data} \longrightarrow \text{train} \mid \text{test}$$

Contoh pembagian dengan NumPy

```
rng = np.random.default_rng(7)
idx = rng.permutation(len(df))

k = int(0.8 * len(df))
train_idx = idx[:k]
test_idx = idx[k:]

train = df.iloc[train_idx]
test = df.iloc[test_idx]
```

Evaluasi sederhana

$\text{MSE} = \frac{1}{m}\sum_{i=1}^{m}(y_i - \hat{y}_i)^2$ mengukur rata-rata kuadrat kesalahan pada data uji.

Regresi Linier Berganda: Bentuk Matriks

Sekarang satu respons dipengaruhi oleh dua prediktor, misalnya

$$y = \text{nilai}, \qquad x_1 = \text{jam belajar}, \qquad x_2 = \text{jumlah latihan}.$$

Modelnya

$$\hat{y}_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2}.$$

Untuk n observasi, seluruh persamaan ditulis serentak sebagai

$$\underbrace{\hat{y}}_{n\times 1} = \underbrace{X}_{n\times 3}\,\underbrace{\beta}_{3\times 1}, \qquad X = \begin{pmatrix} 1 & x_{11} & x_{12} \\ 1 & x_{21} & x_{22} \\ \vdots & \vdots & \vdots \\ 1 & x_{n1} & x_{n2} \end{pmatrix}, \quad \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{pmatrix}.$$

Pertanyaan dimensi

Mengapa bentuknya $X\beta$, bukan βX? **Hint:** tuliskan ukuran kedua matriks sebelum melakukan perkalian.

Least Squares dalam Bentuk Matriks

Data respons, prediksi, dan residual semuanya merupakan vektor di $\mathbb{R}^n$:

$$\underbrace{y}_{n\times 1}, \qquad \underbrace{X\beta}_{n\times 1}, \qquad \underbrace{r = y - X\beta}_{n\times 1}.$$

Norma-2 dan jarak

Dari aljabar linear elementer,

$$\|r\|_2 = \sqrt{r_1^2 + \cdots + r_n^2}.$$

Karena akar kuadrat monoton, meminimumkan $\|r\|_2$ ekuivalen dengan meminimumkan

$$J(\beta) = \|y - X\beta\|_2^2.$$

Kalkulus peubah banyak

$$J(\beta) = (y - X\beta)^T (y - X\beta).$$

Gradien terhadap β:

$$\nabla_\beta J = -2X^T(y - X\beta).$$

Pada minimum, $\nabla_\beta J = 0$, sehingga

$$\boxed{X^T X\beta = X^T y}.$$

Implementasi Regresi Linier Berganda

Ukuran objek untuk dua prediktor

X	$n \times 3$
y	$n \times 1$
X^T	$3 \times n$
$X^T X$	3×3
$X^T y$	3×1
β	3×1
$\hat{y} = X\beta$	$n \times 1$

Prinsip

Gunakan Pandas untuk data dan NumPy untuk operasi numerik. Belum memakai library pemodelan seperti scikit-learn.

```python
import numpy as np
import pandas as pd

df = pd.read_csv("data_regresi_m09.csv")
x1 = df["jam_belajar"].to_numpy()
x2 = df["jumlah_latihan"].to_numpy()
y = df["nilai"].to_numpy()

n = len(df)
X = np.column_stack((np.ones(n), x1, x2))
A = X.T @ X
b = X.T @ y
beta = np.linalg.solve(A, b)
yhat = X @ beta
resid = y - yhat
mse = np.mean(resid**2)
```

Model Machine Learning dan Prinsip Optimisasi

Banyak model machine learning dapat dipandang sebagai pencarian parameter yang membuat suatu fungsi objektif sekecil atau sebesar mungkin.

Masalah	**Contoh model**	**Prinsip matematis**
Regresi	Linear regression	minimisasi kuadrat residual
Klasifikasi	Logistic regression	minimisasi log-loss
Clustering	k-means	minimisasi jarak dalam kelompok
Reduksi dimensi	PCA	eigenvalue/eigenvector, variansi maksimum
Model berlapis	Neural network	minimisasi loss dengan metode berbasis gradien

Fondasi matematika

Aljabar linear: representasi data, parameter, dan transformasi. **Kalkulus peubah banyak**: turunan parsial dan gradien. **Optimisasi**: memilih parameter yang meminimumkan/memaksimumkan objektif.

Supervised Learning, Prediction, dan Forecasting

Supervised learning

Data latih berbentuk pasangan

$$(x_i, y_i), \qquad i = 1, \ldots, n.$$

Model belajar hubungan dari variabel input x menuju target y.

- Jika y numerik: **regression**.
- Jika y berupa kelas: **classification**.

Prediction dan forecasting

Prediction adalah penggunaan model untuk memperkirakan target pada input yang belum digunakan untuk estimasi parameter.

Forecasting adalah prediksi ketika urutan waktu menjadi bagian penting dari masalah, misalnya memperkirakan permintaan bulan berikutnya dari data historis bulanan.

Catatan

Untuk runtun waktu, evaluasi harus menghormati urutan waktu agar informasi masa depan tidak digunakan saat melatih model pada masa lalu.

Latihan (1/2): Estimasi Regresi Linier Berganda dari 10 Data

Gunakan **10 data** berikut dan model

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2,$$

dengan x_1 = jam belajar, x_2 = jumlah latihan, dan y = nilai.

i	1	2	3	4	5	6	7	8	9	10
x_1	2	3	4	5	6	7	8	4	6	9
x_2	3	5	4	6	8	7	9	7	10	11
y	52	58	61	67	74	77	84	65	78	91

Langkah 1–5

1. Bentuk matriks desain X dan vektor y untuk 10 data tersebut.
2. Hitung $X^T X$ dan $X^T y$.
3. Selesaikan $X^T X\beta = X^T y$ hingga diperoleh $\beta_0, \beta_1, \beta_2$.
4. Hitung $\hat{y}$, residual $r = y - \hat{y}$, dan MSE.
5. Tuliskan algoritma perhitungannya, kemudian implementasikan dengan **NumPy dan Pandas saja**.

Lanjutkan hasil dan algoritma ini pada Latihan (2/2).

Latihan (2/2): Generalisasi untuk n Data dan Kompleksitas Algoritma

Lanjutkan algoritma pada Latihan (1/2). Sekarang ganti 10 observasi dengan n **observasi**, sedangkan jumlah prediktor tetap dua.

Langkah 6: Dimensi objek

Tentukan ukuran setiap objek berikut:

$$X : ?, \qquad y : ?, \qquad \beta : ?$$

$$X^T : ?, \qquad X^T X : ?, \qquad X^T y : ?$$

$$\hat{y} : ?, \qquad r : ?$$

Hint: X memiliki satu kolom konstanta dan dua kolom prediktor.

Langkah 7–8: $T(n)$ dan Big-O

Berdasarkan **algoritma yang sama**:

7. Turunkan $T(n)$ dengan menghitung operasi yang bergantung pada jumlah data saat membentuk $X^T X$, $X^T y$, $\hat{y}$, residual, dan MSE. Sistem yang diselesaikan tetap berukuran 3×3.
8. Dari $T(n)$ tersebut, tentukan kelas pertumbuhan Big-O terhadap n.

Pengayaan: jika jumlah prediktor juga bertambah menjadi p, bagian mana dari prosedur yang tidak lagi berukuran tetap?