

Pertemuan 9
Regresi Linier, Least Squares, dan Pandas

Pemrograman untuk Ilmu Data dan Komputasi

MA25-21008

Triyana Muliawati, S.Si., M.Si.
Rifky Fauzi

Program Studi Matematika
Institut Teknologi Sumatera

Semester Ganjil 2026/2027

Era Big Data dan Peran Matematika

Data sebagai objek komputasi

Data modern dapat berukuran besar, banyak variabel, cepat bertambah, dan berasal dari berbagai sumber:

- transaksi dan aktivitas digital;
- sensor, cuaca, dan pengamatan lingkungan;
- proses industri dan produksi;
- data pendidikan, ekonomi, dan sosial.

Peran matematika

Matematika memberi kerangka untuk

- merepresentasikan data sebagai vektor dan matriks;
- merumuskan hubungan antarvariabel;
- menentukan ukuran galat atau fungsi objektif;
- mencari parameter melalui optimisasi;
- memeriksa kewajaran hasil komputasi.

Data $\longrightarrow$ **representasi matematis** $\longrightarrow$ **algoritma** $\longrightarrow$ **informasi**

Pemodelan Hubungan Antarvariabel

Pertanyaan matematis

Untuk pasangan pengamatan (x_i, y_i), matematika dapat digunakan untuk menjawab:

- apakah perubahan x berkaitan dengan perubahan y?
- seberapa besar perubahan y ketika x berubah?
- bagaimana memperkirakan y untuk x yang belum diamati?

Model umum:

$$y_i = f(x_i) + \varepsilon_i.$$

Model linier sebagai pendekatan awal

Pilih fungsi paling sederhana

$$f(x) = b_0 + b_1 x,$$

sehingga

$$y_i = b_0 + b_1 x_i + \varepsilon_i.$$

Menentukan b_0 dan b_1 dari data disebut **regresi linier sederhana**.

Contoh: jam belajar $\rightarrow$ nilai; luas bangunan $\rightarrow$ harga; suhu $\rightarrow$ konsumsi listrik; curah hujan $\rightarrow$ tinggi muka air.

Regresi Linier Sederhana dan Metode Kuadrat Terkecil

Residual dan fungsi objektif

Prediksi untuk titik ke-i:

$$\widehat{y}_i = b_0 + b_1 x_i.$$

Residual:

$$e_i = y_i - \widehat{y}_i.$$

Metode kuadrat terkecil memilih b_0, b_1 yang meminimumkan

$$S(b_0, b_1) = \sum_{i=1}^{n} (y_i - b_0 - b_1 x_i)^2.$$

Kondisi minimum

Dengan

$$\frac{\partial S}{\partial b_0} = 0, \qquad \frac{\partial S}{\partial b_1} = 0,$$

diperoleh

$$b_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}, \qquad b_0 = \bar{y} - b_1 \bar{x}.$$

Rumus koefisien bukan rumus yang muncul begitu saja: ia merupakan solusi masalah minimisasi jumlah kuadrat residual.

Algoritma Regresi Linier Sederhana

Prosedur komputasi

1. Hitung $\bar{x}$ dan $\bar{y}$.
2. Hitung $N = \sum(x_i - \bar{x})(y_i - \bar{y})$.
3. Hitung $D = \sum(x_i - \bar{x})^2$.
4. Jika $D = 0$, model tidak dapat menentukan kemiringan.
5. Hitung $b_1 = N/D$ dan $b_0 = \bar{y} - b_1\bar{x}$.
6. Gunakan $\widehat{y} = b_0 + b_1 x$ untuk prediksi.

```python
def fit_linear(x, y):
    n = len(x)
    xbar = sum(x) / n
    ybar = sum(y) / n

    num, den = 0.0, 0.0
    for xi, yi in zip(x, y):
        num += (xi-xbar)*(yi-ybar)
        den += (xi-xbar)**2

    if den == 0:
        raise ValueError("x tidak bervariasi")

    b1 = num / den
    b0 = ybar - b1*xbar
    return b0, b1
```

Representasi dan Eksplorasi Data Tabular

```python
import pandas as pd

df = pd.read_csv("data_regresi_m09.csv")

print(df.head())
print(df.shape)
print(df.dtypes)
print(df.isna().sum())

# visualisasi hubungan satu prediktor
df.plot.scatter(
    x="jam_belajar",
    y="nilai",
    grid=True
)
```

Struktur data

Dataset latihan mempunyai tiga kolom:

- `jam_belajar`: prediktor pertama;
- `jumlah_latihan`: prediktor kedua;
- `nilai`: variabel respons.

Pada tahap awal, gunakan hanya `jam_belajar` untuk regresi sederhana.

Tujuan eksplorasi

Periksa tipe data, nilai hilang, rentang nilai, dan pola visual sebelum melakukan estimasi parameter.

Estimasi Parameter dan Evaluasi Model

Tujuan pemisahan data

Model dibangun agar pola yang dipelajari dapat digunakan pada data yang tidak ikut menentukan parameter.

- **Training set**: mengestimasi parameter model.
- **Test set**: menilai kinerja model setelah parameter ditentukan.

Salah satu ukuran galat pada test set:

$$\mathrm{MSE} = \frac{1}{m}\sum_{i=1}^{m}(y_i - \widehat{y}_i)^2.$$

```python
import numpy as np

idx = np.arange(len(df))
rng = np.random.default_rng(7)
rng.shuffle(idx)

cut = int(0.7 * len(df))
train = df.iloc[idx[:cut]]
test  = df.iloc[idx[cut:]]

b0, b1 = fit_linear(
    train["jam_belajar"].to_numpy(),
    train["nilai"].to_numpy()
)

yhat = b0 + b1*test["jam_belajar"].to_numpy()
mse = np.mean((test["nilai"].to_numpy()-yhat)**2)
```

Regresi Linier Berganda

Dua prediktor

Misalkan nilai dipengaruhi oleh

$$x_1 = \text{jam belajar},$$

$$x_2 = \text{jumlah latihan}.$$

Model liniernya

$$\widehat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2.$$

Setiap koefisien menyatakan kontribusi satu prediktor ketika prediktor lain dipertahankan.

Dari skalar ke matriks

Untuk n observasi, susun

$$X = \begin{bmatrix} 1 & x_{11} & x_{12} \\ 1 & x_{21} & x_{22} \\ \vdots & \vdots & \vdots \\ 1 & x_{n1} & x_{n2} \end{bmatrix}, \qquad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix}.$$

Maka semua prediksi sekaligus ditulis

$$\widehat{\mathbf{y}} = X\boldsymbol{\beta}.$$

Formulasi Least Squares dalam Bentuk Matriks

Dimensi dan norma Euclid

Untuk dua prediktor:

$$X \in \mathbb{R}^{n\times 3}, \quad \boldsymbol{\beta} \in \mathbb{R}^{3\times 1}, \quad \mathbf{y} \in \mathbb{R}^{n\times 1}.$$

Residual:

$$\mathbf{e} = \mathbf{y} - X\boldsymbol{\beta} \in \mathbb{R}^{n\times 1}.$$

Norma-2 adalah panjang Euclid vektor:

$$\|\mathbf{e}\|_2 = \sqrt{e_1^2 + \cdots + e_n^2}.$$

Maka

$$\|\mathbf{y} - X\boldsymbol{\beta}\|_2^2 = \sum_{i=1}^{n} e_i^2.$$

Masalah least squares

$$\min_{\boldsymbol{\beta}} \ \|\mathbf{y} - X\boldsymbol{\beta}\|_2^2.$$

Kondisi minimum menghasilkan

$$X^T X\boldsymbol{\beta} = X^T\mathbf{y}.$$

Jika $X^T X$ nonsingular,

$$\widehat{\boldsymbol{\beta}} = (X^T X)^{-1} X^T\mathbf{y}.$$

Pertanyaan dimensi

Mengapa $\widehat{\mathbf{y}} = X\boldsymbol{\beta}$, bukan $\boldsymbol{\beta}X$?
Hint: periksa ukuran pada aturan $(a \times b)(b \times c)$.

Implementasi Regresi Linier Berganda

```
import numpy as np

X0 = df[["jam_belajar",
         "jumlah_latihan"]].to_numpy(float)
y = df["nilai"].to_numpy(float)

n = len(df)
X = np.column_stack([np.ones(n), X0])

A = X.T @ X
c = X.T @ y
beta = np.linalg.solve(A, c)

yhat = X @ beta
res = y - yhat
mse = np.mean(res**2)
```

Urutan algoritma

1. Bentuk matriks desain X.
2. Hitung $A = X^T X$.
3. Hitung $c = X^T \mathbf{y}$.
4. Selesaikan $A\boldsymbol{\beta} = c$.
5. Hitung $\widehat{\mathbf{y}} = X\boldsymbol{\beta}$.
6. Hitung residual dan galat.

Hasil pada data contoh

Dengan seluruh 10 observasi,

$$\widehat{y} \approx 45.18 + 3.99x_1 + 1.97x_2.$$

Model Machine Learning dan Prinsip Optimisasi

Prinsip umum pembelajaran model

Banyak metode machine learning dapat dipandang sebagai proses:

pilih $f(x;\theta) \rightarrow$ ukur kesalahan $\rightarrow$ tentukan θ.

Pada regresi linier,

$$L(\beta) = \|y - X\beta\|_2^2.$$

Pada model lain, bentuk model dan fungsi objektif dapat berbeda.

Beberapa keluarga model

- **Regresi:** linear regression, polynomial regression, regression tree, neural network.
- **Klasifikasi:** logistic regression, k-NN, decision tree, SVM, neural network.
- **Pengelompokan:** k-means, hierarchical clustering.
- **Reduksi dimensi:** PCA.

Fokus mata kuliah: memahami representasi matematis, prosedur komputasi, dan evaluasi model sebelum menggunakan library pemodelan.

Pengayaan: Supervised Learning, Prediction, dan Forecasting

Supervised learning

Data tersedia sebagai pasangan

$$(\mathbf{x}_i, y_i).$$

Target y diketahui pada data pelatihan dan dipakai untuk mempelajari hubungan dari prediktor $\mathbf{x}$.

- y numerik $\rightarrow$ regresi;
- y kategori $\rightarrow$ klasifikasi.

Prediction dan forecasting

Prediction adalah perkiraan target yang belum diketahui berdasarkan model.

Forecasting adalah prediction untuk nilai masa depan pada data yang mempunyai urutan waktu. Karena masa depan tidak boleh digunakan untuk melatih masa lalu, pembagian data dilakukan secara kronologis.

Hubungan dengan pertemuan ini

Regresi linier merupakan salah satu model supervised learning untuk target numerik.

Latihan: Regresi Linier Berganda dengan Dua Prediktor

Data

i	x_1 jam	x_2 latihan	y nilai
1	1	2	54
2	2	5	61
3	3	1	61
4	4	6	72
5	5	3	71
6	6	7	84
7	7	4	79
8	8	8	95
9	9	5	90
10	10	9	103

Tugas

Bangun model

$$\widehat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2$$

tanpa library pemodelan. Tuliskan algoritma yang Anda gunakan, kemudian:

1. bentuk X dan y, beserta dimensinya;
2. hitung $X^T X$ dan $X^T y$;
3. selesaikan persamaan normal untuk memperoleh β;
4. hitung prediksi dan residual setiap data;
5. hitung MSE;
6. tuliskan $T(n)$ dari prosedur Anda dan tentukan Big-O, dengan $n =$ jumlah observasi dan jumlah prediktor tetap dua.